

algorytm, umożliwiający obliczenie dla każdej pozycji  $i$  maksymalnego promienia  $R[i]$  palindromu o środku na pozycji  $i$  (promieniem palindromu  $vv^R$  jest długość  $v$ ), a dokładniej

$$R[i] = \max\{k \geq 0: x[i-k+1..i] = (x[i+1..i+k])^R\}$$

{Algorytm Manachera; obliczanie promieni słów symetrycznych}

```
begin
  {przyjmijmy, że  $x[1] = \$$ ,  $x[n] = \#$ }
   $R[1] := 0$ ;  $i := 2$ ;  $j := 0$ ;
  while ( $i \leq n$ ) do
    begin
      while  $x[i-j] = x[i+j+1]$  do  $j := j+1$ ;
       $R[i] := j$ ;
       $k := 1$ ;
      while ( $R[i-k] \neq R[i+k]$  and ( $k \leq j$ )) do
        begin  $R[i+k] := \min(R[i-k], R[i+k])$ ;  $k := k+1$  end;
       $j := \max(j-k, 0)$ ;  $i := i+k$ 
    end
  end
end {algorytm Manachera};
```

Poprawność algorytmu wynika z następującej własności promieni palindromów: jeśli dla  $k = 1..R[i]$  mamy  $R[i-k] \neq R[i+k]$ , to  $R[i+k] = \min(R[i-k], R[i+k])$ .

Operacjami dominującymi w algorytmie są porównania  $x[i-j] = x[i+j+1]$ . Porównań takich z wynikiem negatywnym jest wykonywanych co najwyżej  $n$ , a dla każdej wartości  $i$  co najwyżej jedno. W porównaniach z wynikiem pozytywnym wzrasta wartość sumy  $i+j$ . Wartość ta (przy porównywaniu symboli) nie maleje. Ponieważ maksymalną wartością  $i+j$  jest  $n$ , całkowita liczba wykonanych porównań symboli nie przekracza  $2n$ .

### 5.3.5.

#### Równoważność cykliczna

Dwa słowa są cyklicznie równoważne, gdy są równe w sensie list cyklicznych, co zapisujemy jako  $x \equiv y$ . Problem polega na sprawdzeniu, czy dwa dane słowa są cyklicznie równoważne.

Wystarczy skorzystać z następującego faktu:  $x \equiv y$  wtedy i tylko wtedy, gdy  $x$  występuje (jako wzorzec) w tekście  $yy$ . Zakładamy tutaj, że  $|x| = |y|$ . Problem sprowadza się więc do problemu WW i jego koszt jest liniowy. Istnieje jednak prostszy algorytm, który nie wymaga wyszukiwania wzorca i korzystania z dodatkowej tablicy (pamięć  $O(1)$ ). Niech  $<$  będzie dowolnym porządkiem liniowym na zbiorze symboli.

{Algorytm sprawdzania, czy  $u \equiv w$ ; niech  $x = ww\$, y = uuu\$, n = |u|$ }

```
begin
   $i := 0$ ;  $j := 0$ ;  $k := 1$ ;
  while ( $i < n$ ) and ( $j < n$ ) and ( $k \leq n$ ) do
    begin
       $k := 1$ ;
      while  $x[i+k] = y[j+k]$  do  $k := k+1$ ;
      if ( $k \leq n$ ) then
        begin if  $x[i+k] > y[j+k]$  then  $i := i+k$  else  $j := j+k$  end;
        {niezmiennik *}
      end;
      if ( $k > n$ ) then return ( $u \equiv w$ ) else return (nie zachodzi  $u \equiv w$ )
    end
  end {algorytm};
```

Niech  $u^{(k)} = u[k+1..n]u[1..k]$ , a więc niech  $u^{(k)}$  powstaje przez cykliczne przesunięcie  $u$ . Niech  $D1 = \{1 \leq k \leq n: u^{(k-1)} \gg u^{(0)} \text{ dla pewnego } j\}$  i niech  $D2 = \{1 \leq k \leq n: u^{(k-1)} \gg w^{(0)} \text{ dla pewnego } j\}$ , gdzie  $\gg$  oznacza rozszerzenie  $>$  na słowa (leksykograficznie). Poprawność algorytmu wynika stąd, że jeśli  $D1$  lub  $D2$  jest zbiorem  $\{1, 2, \dots, n\}$ , to nie zachodzi  $u \equiv w$ . Ponadto zachodzi niezmiennik  $*: \{1, 2, \dots, i\} \subseteq D1, \{1, 2, \dots, j\} \subseteq D2$ . Algorytm ma złożoność liniową. Największa liczba porównań symboli jest wykonywana dla słów  $u$  i  $w$  postaci (odpowiednio) 11...1201, 111...120.

### 5.3.6.

#### Algorytm Huffmana

Kompresję tekstów można rozumieć na różne sposoby. Dla nas będzie ona oznaczać redukcję binarnego zapisu danego tekstu. Załóżmy, że dla danego tekstu  $x = a_1 a_2 \dots a_n$  i alfabetu  $I$  chcemy znaleźć jednoznaczny kod  $h$  symboli  $a_i$  alfabetu słowami binarnymi  $h(a_i)$  tak, żeby długość tekstu  $h(a_1) \cdot \dots \cdot h(a_n)$  była minimalna. Rozważamy tutaj klasę takich kodowań, że  $h(a_i)$  nie jest prefiksem  $h(a_j)$  dla żadnych dwóch różnych symboli  $a_i$  i  $a_j$ . Zbiór kodów symboli możemy reprezentować drzewem, którego ścieżki odpowiadają kodom poszczególnych symboli. Bit 0 oznacza „idź w lewo” w drzewie, a bit 1 – „idź w prawo”.

Rozważmy przykład  $x = abcdcdcddb$ . Jeżeli zakodujemy każdy symbol ciągiem dwubitowym, to otrzymany kod będzie miał długość  $2n = 20$ . Przedstawimy teraz algorytm opracowany przez D. Huffmana. Istota tego algorytmu sprowadza się do kodowania częściej występujących symboli krótszymi ciągami binarnymi, a rzadziej występujących symboli – dłuższymi. Przedstawimy na naszym przykładzie działanie algorytmu w wersji rekurencyjnej. Częstość występowania w słowie  $x$  poszczególnych symboli jest następująca:

$$\text{częstość}(a) = 1, \text{częstość}(b) = 2, \text{częstość}(c) = 3, \text{częstość}(d) = 4.$$